Projeto Final - Diagnóstico de Distúrbio da Tireoide

Curso: Profissão Cientista de Dados

Tema escolhido: Hipertireoidismo / Distúrbio da tireoide

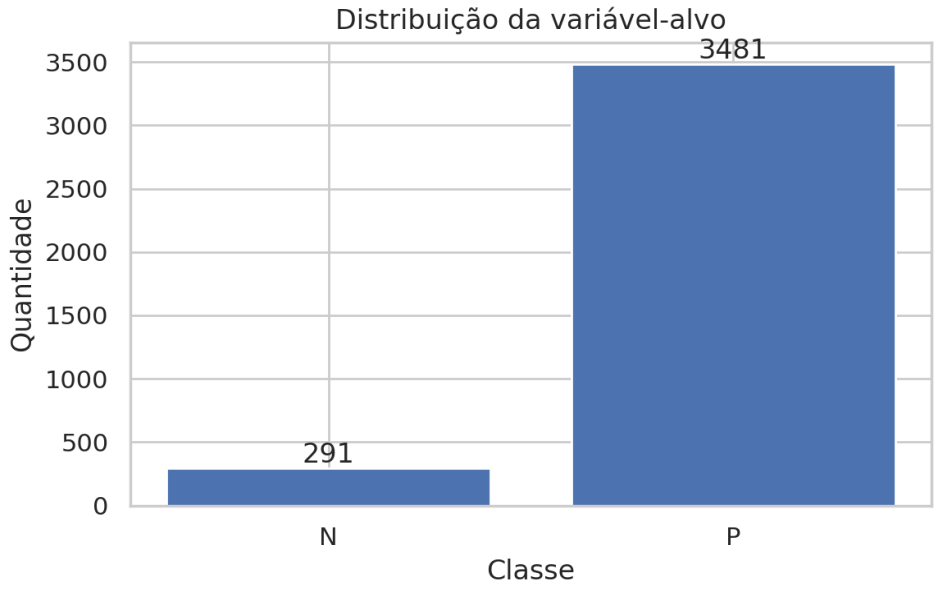
1. Contexto

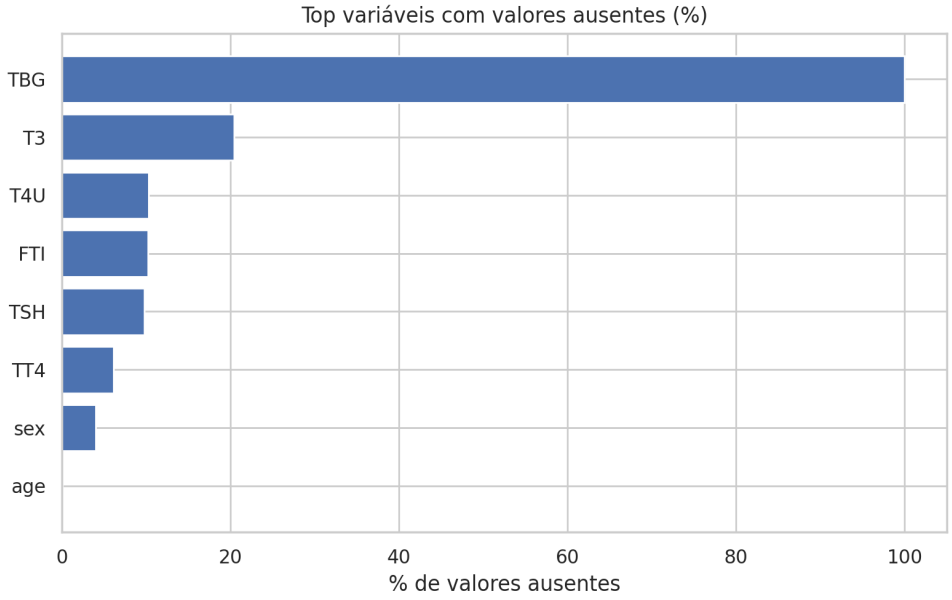
O briefing do curso descreve um desafio de diagnóstico de hipertireoidismo com foco em minimizar falsos negativos. Entretanto, a base efetivamente entregue ao aluno apresenta diferenças em relação ao vídeo: possui 3772 registros, 30 colunas e alvo binário ('P' e 'N'). Por isso, o projeto foi desenvolvido com transparência metodológica, modelando a base real disponibilizada.

2. Base de dados

Após a leitura da base, foram identificados valores faltantes representados por '?', mistura de variáveis numéricas e categóricas e uma coluna completamente vazia (TBG), removida da modelagem.

Indicador	Valor
Linhas	3772
Colunas	30
Classes da variável-alvo	P e N
Classe P	3481 registros (92,29%)
Classe N	291 registros (7,71%)
Coluna removida	TBG (100% ausente)





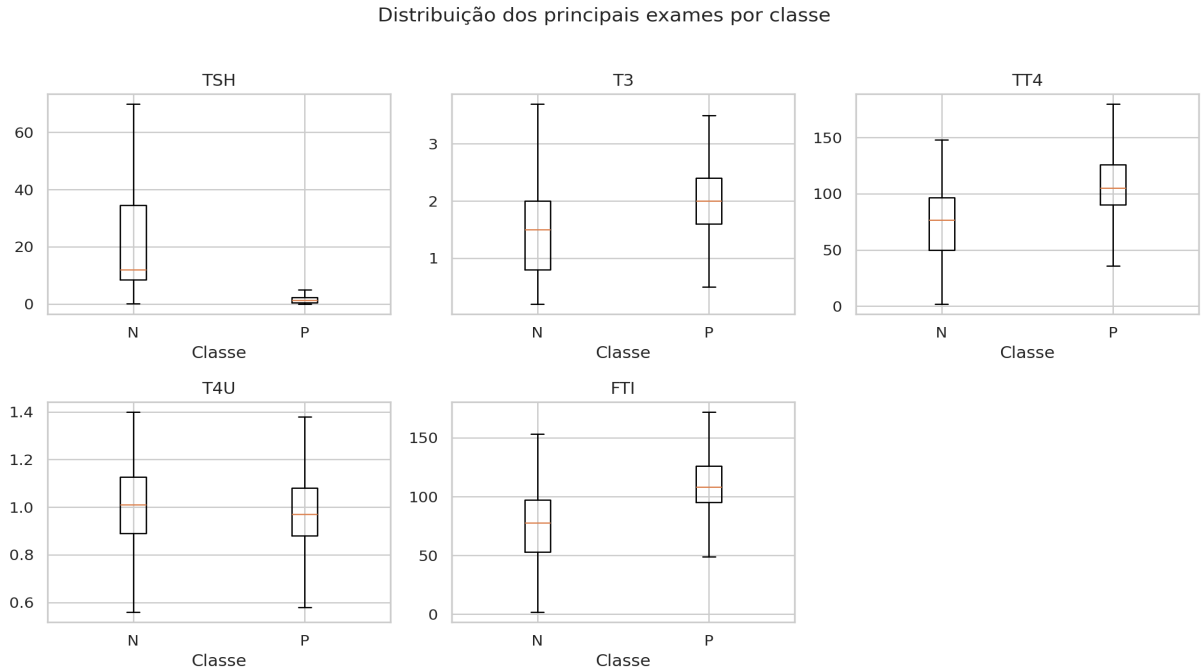
3. Principais achados exploratórios

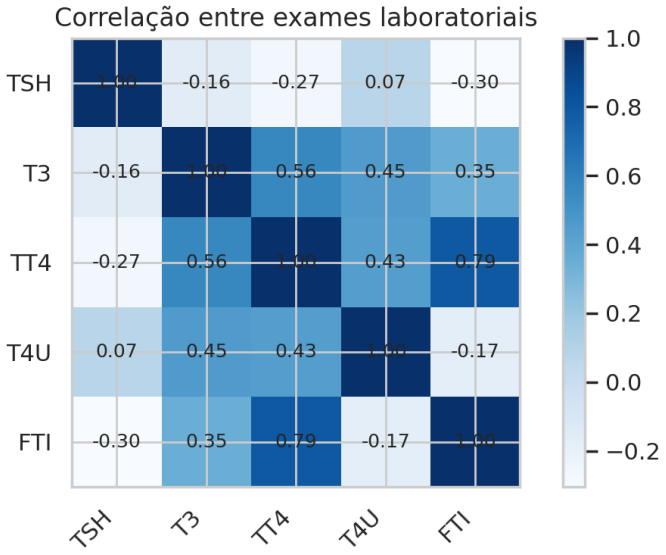
- A variável-alvo é fortemente desbalanceada, com predominância da classe P.

- Exames como TSH, T3, TT4, T4U e FTI mostram poder discriminativo entre as classes.

- A presença de muitas variáveis binárias clínicas e laboratoriais favorece a construção de um pipeline supervisionado.

- Como o objetivo do negócio é minimizar falsos negativos, o recall da classe positiva foi priorizado.

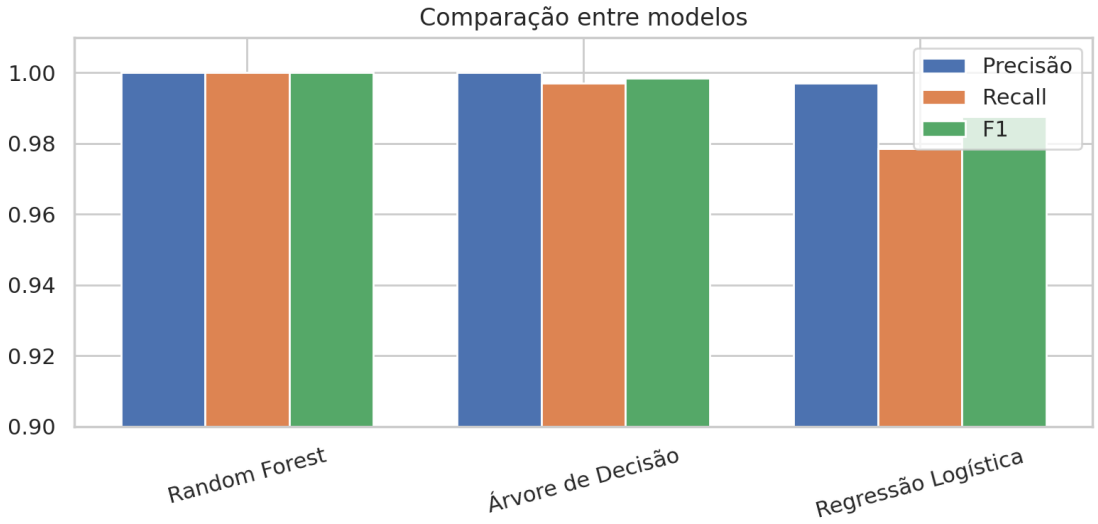



Correlação entre exames laboratoriais
TSH
T3
TT4
T4U
FTI
1.00
-0.16
-0.27
0.07
-0.30
-0.16
1.00
0.56
0.45
0.35
-0.27
0.56
1.00
0.43
0.79
0.07
0.45
0.43
1.00
-0.17
-0.30
0.35
0.79
-0.17
1.00
1.0
0.8
0.6
0.4
0.2
0.0
−0.2

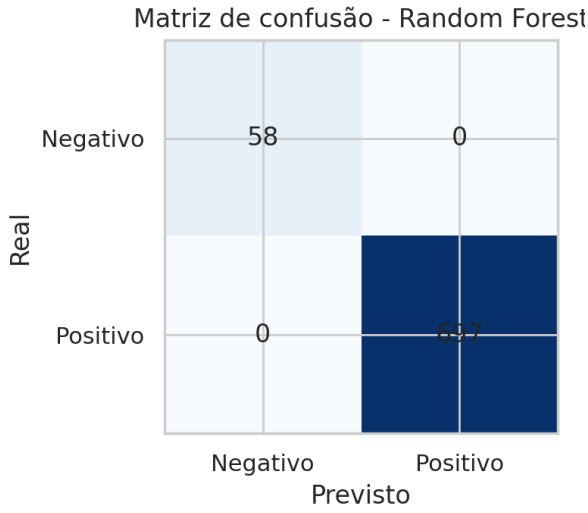
4. Modelagem

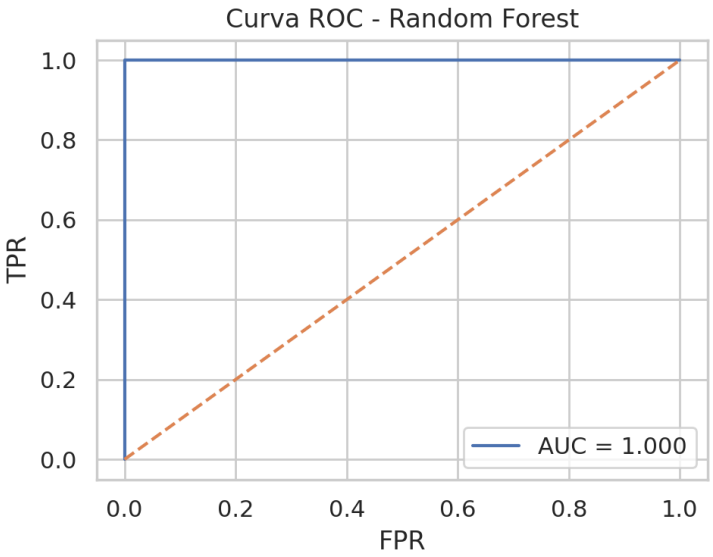
Foram comparados três algoritmos: Regressão Logística, Árvore de Decisão e Random Forest. O pré-processamento incluiu imputação por mediana para variáveis numéricas, imputação pela moda para categóricas, padronização e One-Hot Encoding.

Modelo	Acurácia	Precisão (classe positiva)	Recall (classe positiva)	F1-score	ROC AUC
Random Forest	1.0000	1.0000	1.0000	1.0000	1.0000
Árvore de Decisão	0.9974	1.0000	0.9971	0.9986	0.9986
Regressão Logística	0.9775	0.9971	0.9785	0.9877	0.9928



O modelo final escolhido foi o **Random Forest**, que obteve o melhor equilíbrio entre as métricas e desempenho máximo no conjunto de teste analisado.




Curva ROC - Random Forest
TPR
FPR
AUC = 1.000
0.0
0.2
0.4
0.6
0.8
1.0

5. Threshold e foco em falsos negativos

threshold	precision	recall	f1	false_negatives	false_positives
0.3	0.9887	1.0000	0.9943	0	8
0.4	0.9971	1.0000	0.9986	0	2
0.5	1.0000	1.0000	1.0000	0	0
0.6	1.0000	0.9986	0.9993	1	0
0.7	1.0000	0.9957	0.9978	3	0

Mesmo avaliando limiares diferentes, o Random Forest se manteve muito forte. No conjunto de teste, o threshold de 0,5 já produziu resultado máximo, sem falsos negativos observados.

6. Conclusão

O projeto conseguiu entregar uma solução preditiva robusta para a base fornecida, com bom tratamento de dados, análise exploratória visual e comparação entre modelos. Do ponto de vista do negócio, o resultado é promissor porque atende ao objetivo de reduzir o risco de não identificar casos positivos.

Como limitações, é essencial registrar a divergência entre o briefing e o arquivo entregue, além do fato de os resultados terem sido extremamente altos, o que pede validação adicional em ambiente real e com dados externos.